

## 7.4 PROBLEMA DE MÍNIMOS CUADRADOS III

Si  $A \in \mathbb{R}^{n \times n}$  es invertible, pero  $\sigma_m \ll \sigma_1$   
 mucho menor

$\Rightarrow K_2(A) = \frac{\sigma_1}{\sigma_m} \gg 1$  : número de condición grande  
 ↪ punto 4) de la proposición de la última clase

" $Ax = b$ " es un problema mal condicionado

recordar la clase sobre el número de condición:

se pueden tener errores grandes

- sobre el producto  $Ax$ , si hay error en  $x$
- sobre la solución  $x$ , si hay error en  $b$  o en  $A$

esto se puede entender mirando a la solución


$$x(b) = \sum_{k=1}^n \frac{1}{\sigma_k} \langle b, U^{(k)} \rangle V^{(k)}$$

esta combinación lineal puede dar mucha más importancia a  $V^{(n)}$  que a  $V^{(1)}$  ||

ejemplo (extremo):

$$b = U^{(1)} + U^{(n)}, \quad \sigma_1 = 1, \quad \sigma_n = \frac{\varepsilon}{2} \quad \leftarrow \varepsilon = \text{epsilon máquina}$$

$$\Rightarrow x(b) = V^{(1)} + \frac{2}{\varepsilon} V^{(n)} = \frac{2}{\varepsilon} \left( V^{(n)} + \frac{\varepsilon}{2} V^{(1)} \right)$$



en precisión finita (floating point)

$$1 + \frac{\varepsilon}{2} = 1 \Rightarrow \hat{x(b)} = \frac{2}{\varepsilon} V^{(n)} \quad \text{representación numérica}$$

hemos perdido la dirección  $V^{(1)}$ !

$$\text{además } Ax(b) = b = U^{(1)} + U^{(n)}, \text{ pero } A\hat{x(b)} = U^{(n)}$$

hemos perdido la dirección  $U^{(1)}$ !


¿qué está pasando?

- recordemos que estamos tomando  $A \in \mathbb{R}^{m \times m}$  invertible
- sabemos que  $\{V^{(1)} \dots V^{(m)}\}$  BON de  $\mathbb{R}^m$

$\Rightarrow$  todo  $x \in \mathbb{R}^m$  se escribe  $x = \sum_{k=1}^m \langle x, V^{(k)} \rangle V^{(k)}$

- hemos visto que  $AV^{(k)} = \sigma_k U^{(k)}$ ,  $k=1 \dots m$

$\Rightarrow Ax = \sum_{k=1}^m \sigma_k \langle x, V^{(k)} \rangle U^{(k)}$  ← como en el punto 2) de la proposición de la clase anterior



los coeficientes de esta combinación lineal son productos  $\sigma_k \langle x, V^{(k)} \rangle$ : cuánto más grande es  $\sigma_k$ , tanto más  $A$  da importancia a  $\langle x, V^{(k)} \rangle$ , la componente de  $x$  en la dirección  $V^{(k)}$

↳ como  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m$ , la que tiene más importancia es  $\langle x, V^{(1)} \rangle$

- cuando se calcula  $x(b) = \sum_{k=1}^m \frac{1}{\sigma_k} \langle b, U^{(k)} \rangle V^{(k)}$

si hay demasiada diferencia entre  $\sigma_1$  y  $\sigma_m$  puede pasar que la componente de  $x(b)$  en la dirección  $V^{(1)}$  se pierda, como en el ejemplo, o que sufra de todas formas una pérdida de precisión por errores de redondeo

↳ se tiene un error justo donde no se debería

- algo así pase para todos los términos de la suma: también  $\langle x, V^{(2)} \rangle$  podría perder precisión si  $\frac{\sigma_2}{\sigma_m}$  es demasiado grande ...

una posible solución al problema de encontrar soluciones a sistemas mal condicionados es la REGULARIZACIÓN de Tikhonov: reemplazar  $Ax = b$  por un problema que tiene un número de condición más bajo, y es "parecido"

↳ se fija un parámetro  $\alpha > 0$  y se busca

$$\arg \min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2 + \alpha \|x\|_2^2 \quad \text{Problema III}$$

- es una mezcla de los problemas I y II porque se quiere  $\|Ax - b\|$  y  $\|x\|$  pequeñas, pero ahora se minimizan a la vez
- $\alpha$  es un parámetro de "trade-off": da un balance entre la importancia que tiene minimizar  $\|Ax - b\|$  y la que tiene minimizar  $\|x\|$ :
  - $\alpha$  grande: es más importante que  $\|x\|$  sea pequeña
  - $\alpha$  pequeño: es más importante que  $\|Ax - b\|$  sea pequeña

teorema: sea  $A \in \mathbb{R}^{m \times n}$ , sea  $\alpha > 0$  y sea

$$f_{\alpha}(x) = \|Ax - b\|_2^2 + \alpha \|x\|_2^2$$

1) la solución al problema de encontrar

$$\arg \min_{x \in \mathbb{R}^n} f_{\alpha}(x)$$

es dada por la solución al sistema

$$(A^t A + \alpha I) x = A^t b \quad (*)$$

2) si  $A = U \Sigma V^t$  es la SVD de  $A$ , la solución del sistema (\*) es

$$x_{\alpha}(b) = \sum_{k=1}^n \frac{\sigma_k}{\sigma_k^2 + \alpha} \langle b, U^{(k)} \rangle V^{(k)}$$

observaciones:

- la matriz del sistema (\*) es  $A^t A + \alpha I$  esta es una matriz invertible, porque su núcleo es  $\{0\}$ : si  $x \in \text{Ker}(A^t A + \alpha I)$

$$A^t A x + \alpha x = 0 \rightarrow A^t A x = -\alpha x$$

$\Downarrow$

$$x = 0 \quad \Leftrightarrow \quad \underbrace{\langle A^t A x, x \rangle}_{\|Ax\|^2} = -\alpha \underbrace{\langle x, x \rangle}_{\|x\|^2}$$

- los números  $\frac{\sigma_k}{\sigma_k^2 + \alpha}$  no sufren del problema anterior cuando  $\sigma_m < \sigma_1$

# Aplicación (MATLAB)

consideremos la matriz  $A = \frac{1}{3} \begin{pmatrix} 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 & 1 \end{pmatrix}$

$$A \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ x_6 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} x_1 + x_2 \\ x_1 + x_2 + x_3 \\ x_2 + x_3 + x_4 \\ x_3 + x_4 + x_5 \\ x_4 + x_5 + x_6 \\ x_5 + x_6 \end{pmatrix} \left. \vphantom{\begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ x_6 \end{pmatrix}} \right\} \begin{array}{l} \text{en estas componentes} \\ \text{centrales, tenemos} \\ (Ax)_i = \frac{x_{i-1} + x_i + x_{i+1}}{3} \end{array}$$

↓  
promedio a 3 puntos

este misma construcción se puede hacer en  $\mathbb{R}^n$ , con promedios a  $d$  puntos y, si  $d$  es impar, obtener una  $A$  tal que

$$Ax_i = \frac{1}{d} \sum_{j=i-\lfloor \frac{d}{2} \rfloor}^{i+\lfloor \frac{d}{2} \rfloor} x_j$$

↳ sea  $x$  el vector conteniendo el número de casos diarios de covid 19 detectados en España desde el 1 enero 2020:

$x_1$  = casos diarios el 1 enero 2020

$x_2$  = " 2 "

$x_i$  = "  $(i-1)$  días después del 1 enero 2020

si  $d=21$ , entonces  $b = Ax$  es el vector que, en cada componente, registra el promedio de casos diarios de covid detectados en los 3 semanas alrededor de la fecha


pregunta: conociendo la matriz de promedios  $A$  y el vector  $b$ , obtenido por promedio  $b = Ax$  sobre los datos reales  $x$ ,  
¿es posible reconstruir  $x$ ?

- es un problema  $Ax = b$  donde ahora  $x$  es la incógnita
- seguramente  $b \in \text{Ran}(A)$ , por construcción
- por otro lado, parece intuitivamente muy difícil reconstruir los datos originales a partir de los promedios sobre 3 semanas

¿de dónde nos viene esta intuición?

del hecho que sabemos (aunque quizás no lo sabemos en estos términos) que  $A$  es una matriz mal condicionada

↙  
en general ni es invertible (aunque si para ciertos valores de  $m$  y  $d$  puede serlo) pero, como  $b \in \text{Ran}(A)$ , realmente no es esto lo que preocupa




Valores singulares de la matriz  $A$   $1000 \times 1000$  de promedio sobre 101 puntos:

decrecen muy rápido y van a cero ↴

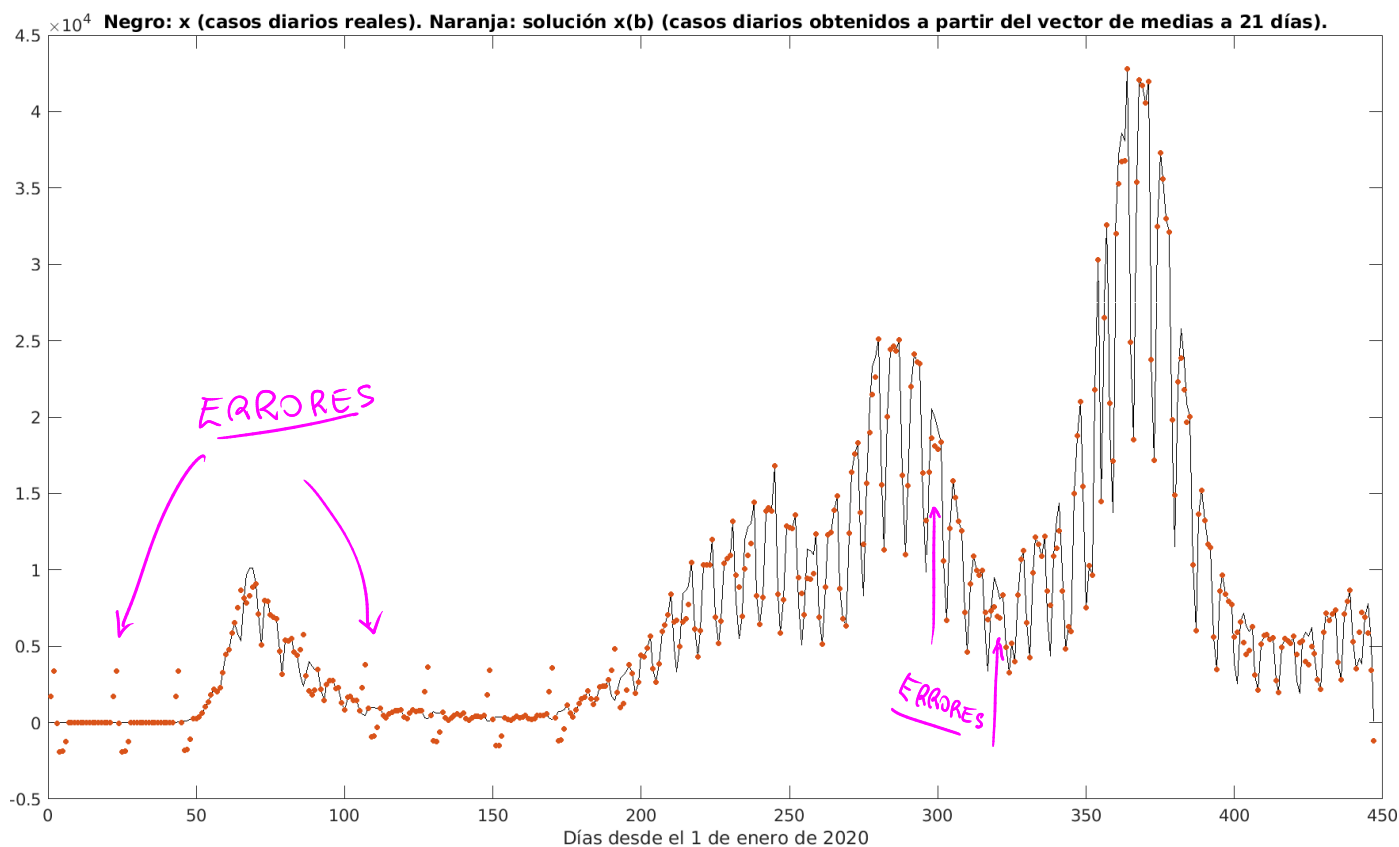
muy mal condicionada

~

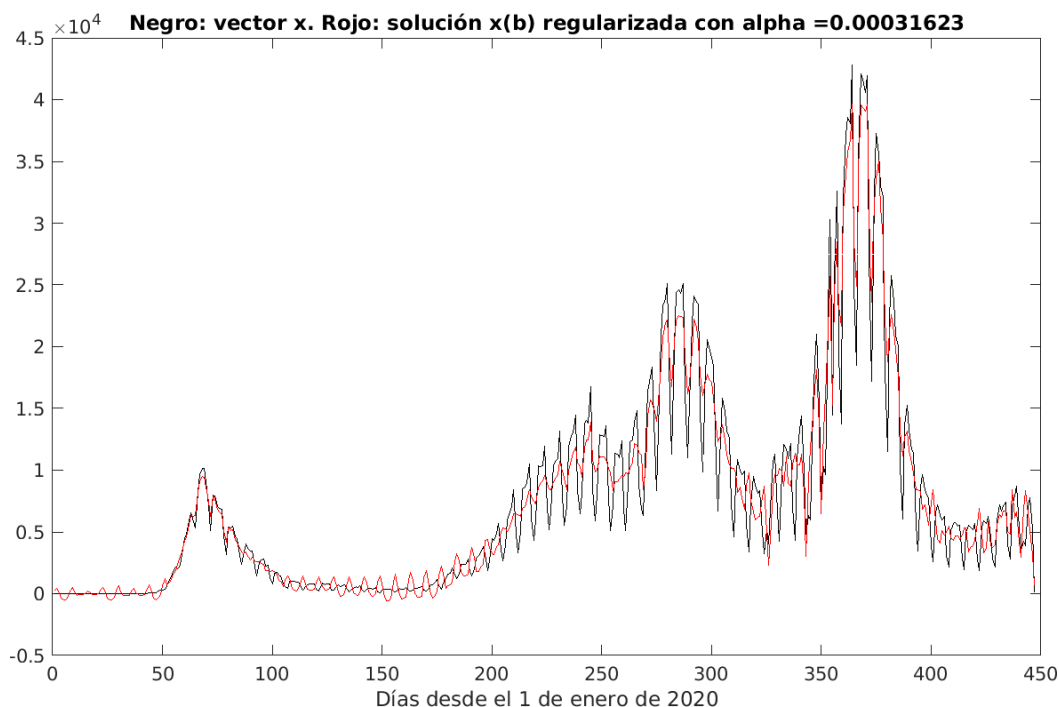
lo que sigue son figuras generadas con el MATLAB script `medias.m`, que se puede descargar junto con este clase



casos diarios de covid detectados en España en 447 días, y su promedio sobre 21 días



aquí en naranja se hace un plot del vector  
 $x(b) = \sum_{k=1}^r \frac{1}{\sigma_k} \langle b, U^{(k)} \rangle V^k$ , obtenido a partir  
 del vector  $b$  en azul de la figura exterior  
 ~~~~~



en rojo la  
 solución  
 regularizada  
 para un cierto  
 valor de  $\alpha$   
 mínimo de  
 $f_\alpha$  dado por  
 el teorema

↳ este tampoco es perfecto: la solución exacta no  
 se puede recuperar por los errores numéricos!